



# Tarea 3 — Análisis de Series de Tiempo

Curso: Análisis de Datos

Autor: Carlos Solares

Fecha: 31/10/2025

## Objetivo general

Analizar el comportamiento de dos procesos estocásticos fundamentales:

1. **Ruido blanco** — proceso sin dependencia temporal.
2. **Proceso autoregresivo AR(1)** — proceso con dependencia del pasado.

Se estudian sus propiedades de **estacionariedad, autocorrelación y estimación de parámetros**.

## 🧩 Fundamentos teóricos

- Una **serie de tiempo** es una realización de un proceso aleatorio dependiente del tiempo.
- En un proceso estacionario:
  - $E[X_t] = \mu$
  - $\text{Var}(X_t) = \sigma^2$
  - $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$
- La **función de autocorrelación (ACF)** mide:

$$r(h) = \frac{\text{Cov}(X_t, X_{t-h})}{\text{Var}(X_t)}$$

## Inciso 1 — Simetría de $\gamma(h)$

**Definición:**  $\gamma(h) = \text{Cov}(X_t, X_{t+h})$ .

**Prueba (bajo estacionariedad débil):**

1.  $\gamma(-h) = \text{Cov}(X_t, X_{t-h})$ .
2. Reindexa con  $s = t - h$ :  $\gamma(-h) = \mathbb{E}[(X_{s+h} - \mu)(X_s - \mu)]$ .
3. Conmutatividad:  $(X_{s+h} - \mu)(X_s - \mu) = (X_s - \mu)(X_{s+h} - \mu)$ .
4. Estacionariedad  $\rightarrow$  depende solo de  $h$ :  $\gamma(-h) = \gamma(h)$ .

**Conclusión:** la función de autocovarianza es **par** (simétrica).

## Inciso 2 (a) — ¿Por qué es deseable la estacionariedad?

- Reglas estables en el tiempo (media, varianza, covarianzas no cambian).
- Modelos más simples/robustos (ARMA/ARIMA suelen asumirla).
- Pronósticos más confiables (no cambian “las reglas del juego”).
- Comparabilidad temporal entre periodos.

**Inciso 2 (b) — ¿Es  $Y_t = a + bt + \varepsilon_t$  estacionaria?**

Supuestos:  $\mathbb{E}[\varepsilon_t] = 0$ ,  $\text{Var}(\varepsilon_t) = \sigma^2$ ,  $\text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = 0$  ( $h \neq 0$ ).

- $\mathbb{E}[Y_t] = a + bt$  depende de  $t \rightarrow$  no estacionaria si  $b \neq 0$ .
- $\text{Var}(Y_t) = \sigma^2$  (constante).
- $\gamma_Y(h) = 0$  para  $h \neq 0$ .

**Conclusión:** no estacionaria salvo  $b = 0$ .

## Inciso 2 (c) — ¿Cómo hacerla estacionaria?

- **Detrending** (quitar  $a + bt$ ):

$$Z_t = Y_t - (a + bt) = \varepsilon_t \text{ (ruido blanco, estacionario).}$$

*En práctica:* estima  $\hat{a}, \hat{b}$  por MCO y usa residuales.

- **Diferenciación:**

$$\Delta Y_t = Y_t - Y_{t-1} = b + (\varepsilon_t - \varepsilon_{t-1}) \text{ (MA(1) + constante, estacionario).}$$

Centra si quieres media cero:  $\Delta Y_t - b$ .

## Inciso 3 — Función de autocorrelación muestral

Definición:

$$r(h) = \frac{\sum_{t=h+1}^T (X_t - \bar{X})(X_{t-h} - \bar{X})}{\sum_{t=1}^T (X_t - \bar{X})^2}, \quad h = 0, 1, \dots$$

¿Qué mide?

- Relación lineal entre  $X_t$  y  $X_{t-h}$ .
- $r(h) \in [-1, 1]$ ; cercano a 0  $\rightarrow$  poca memoria; cercano a  $\pm 1 \rightarrow$  fuerte dependencia.

**Uso típico:** detectar memoria, periodicidades, y guiar elección de modelos (p. ej., AR vs MA).



## Inciso 3 — Ruido Blanco

Proceso simulado

$$X_t \sim \mathcal{N}(0, 1)$$

- No presenta memoria ni correlación temporal.
- La ACF debe ser  $\approx 0$  para todo  $h \geq 1$ .

## ⚙ Implementación


```
cd "Inciso 3"
python -m venv .venv
.venv\Scripts\Activate.ps1      # En Windows (PowerShell)
# source .venv/bin/activate     # En macOS/Linux
pip install numpy matplotlib

python simulate_white_noise_acf.py --n 1000 --lags 40
```

- Se generan 1000 observaciones.
- Se calcula la ACF muestral.
- Se grafican la serie y su ACF con bandas  $\pm 1.96/\sqrt{T}$ .




## Resultados — Serie simulada



- Distribución normal sin tendencia.
- Valores centrados en cero.



## Resultados — ACF del ruido blanco



- La ACF es  $\approx 0$  para todos los lags (dentro de bandas).
- Confirma independencia temporal → **ruido blanco**.

**Inciso 4 —  $Y = X\beta + \varepsilon$  vs  $X_t = \phi X_{t-1} + \varepsilon_t$**

Regresión clásica (OLS):

- $\mathbb{E}[\varepsilon] = 0, \text{Var}(\varepsilon) = \sigma^2 I,$
- **Independencia** (no autocorrelación):  $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$  si  $i \neq j$ .

AR(1):

- Observaciones dependen del pasado → hay autocorrelación.

Si ignoras la dependencia temporal en OLS:

- Se viola la independencia de errores.
- Errores estándar y tests (t/F) **incorrectos**; estimadores no eficientes.

## Inciso 5 (a) — AR(1): media y varianza bajo estacionariedad

Modelo:  $X_t = \phi X_{t-1} + \varepsilon_t$ ,  $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ .

- $\mathbb{E}[X_t] = 0$  (para  $|\phi| < 1$ ).
- $\text{Var}(X_t) = \frac{\sigma^2}{1 - \phi^2}$ .

## Inciso 5 (b) — Condición de estacionariedad

- Si  $|\phi| < 1 \Rightarrow X_t = \sum_{j \geq 0} \phi^j \varepsilon_{t-j}$  (converge en  $L^2$ )  $\Rightarrow$  estacionario.
- Si  $|\phi| \geq 1 \Rightarrow$  varianza no acotada (p. ej.,  $\phi = 1$ : random walk)  $\Rightarrow$  no estacionario.

Equivalente: AR(1) es estacionario ssi  $|\phi| < 1$ .

## Inciso 5 (c) — ACF del AR(1)

Autocovarianza:  $\gamma(h) = \frac{\sigma^2}{1 - \phi^2} \phi^{|h|}$ .

ACF:  $\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \phi^{|h|}$ .

Interpretación: decae geométricamente con  $h$ .



## Inciso 6 — Proceso AR(1)

### Modelo

$$X_t = \phi X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2)$$

Parámetros:

$$\phi = 0.7, \quad \sigma = 1, \quad T = 200$$

- La ACF teórica es  $r(h) = \phi^{|h|}$ .
- Se espera un decrecimiento geométrico con  $h$ .

## ⚙ Implementación

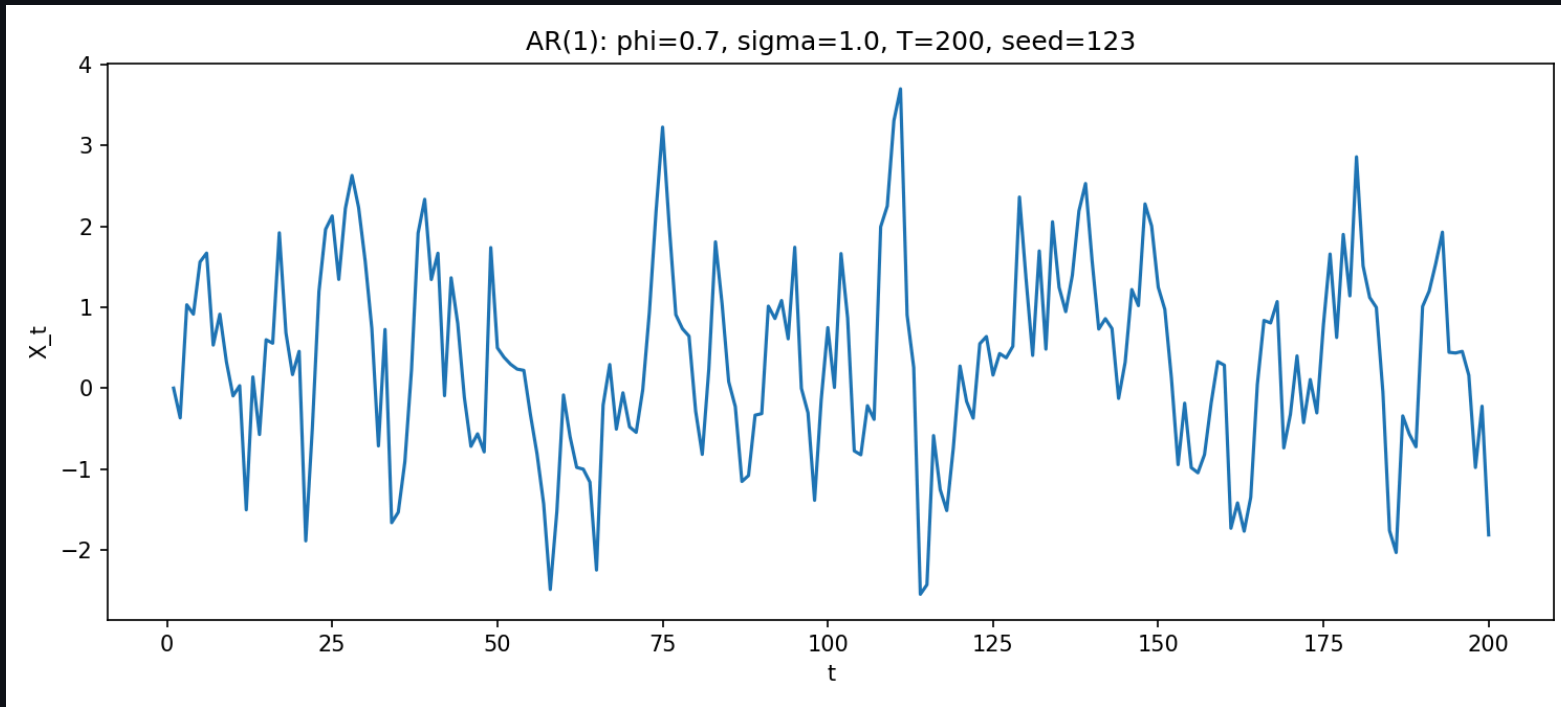
```
cd "Inciso 6"
python -m venv .venv
.venv\Scripts\Activate.ps1      # En Windows (PowerShell)
# source .venv/bin/activate     # En macOS/Linux
pip install numpy matplotlib

python simulate_ar1_acf.py --phi 0.7 --sigma 1 --T 200 --lags 40
```

- Simula AR(1) estacionario.
- Calcula la ACF muestral.
- Estima  $\hat{\phi}$  con OLS en  $X_t = \beta X_{t-1} + \varepsilon_t$ .



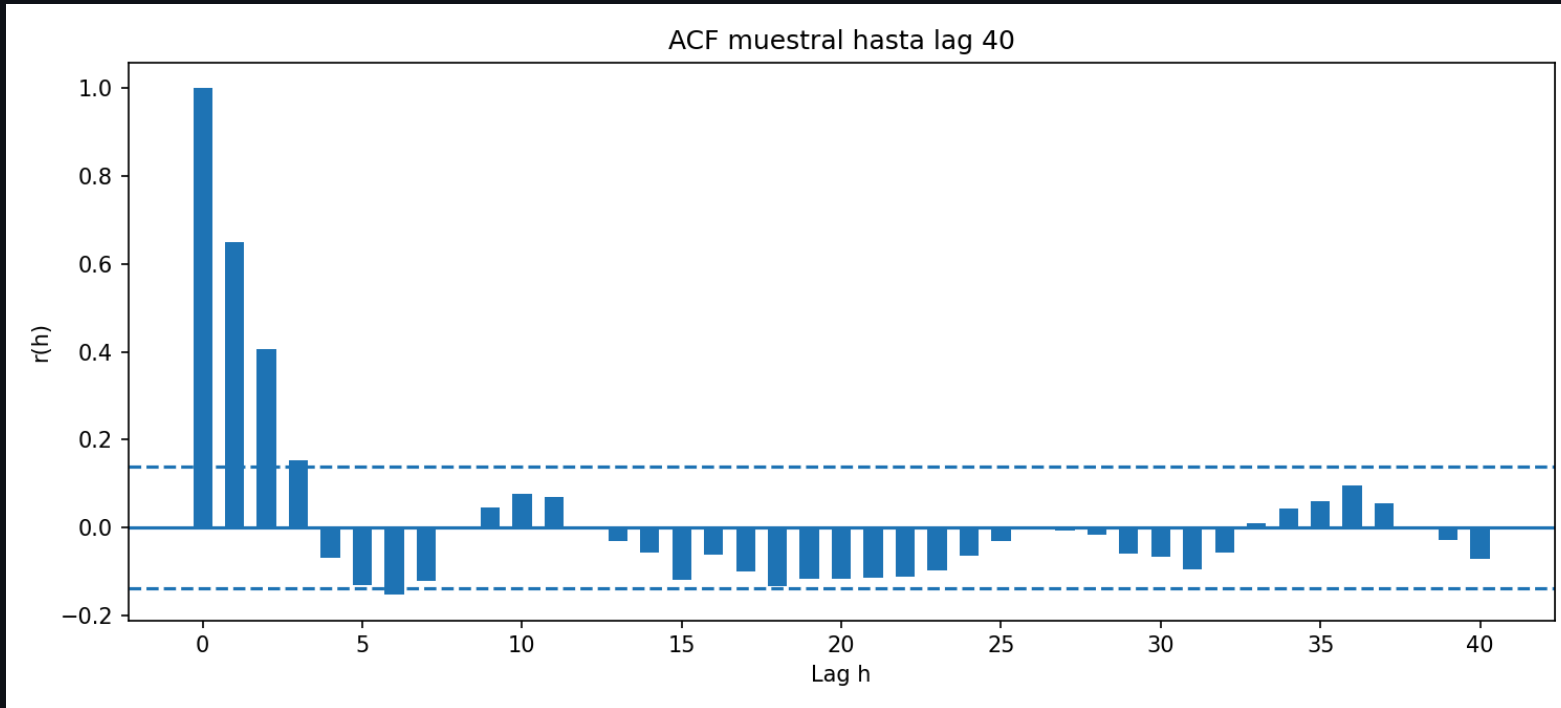
## Serie AR(1) simulada



- Presenta correlación positiva entre periodos consecutivos.
- Valores suavizados por el efecto de memoria.



## ACF del proceso AR(1)



- ACF decrece geométricamente con  $h$ .
- Forma típica de un **proceso autoregresivo**.
- Confirma dependencia temporal.

## Estimación de $\phi$

Regresión lineal:

$$X_t = \beta X_{t-1} + \varepsilon_t$$

Resultado:

$$\hat{\phi} \approx 0.7$$

➡ Estimación **muy cercana** al valor real → OLS válido bajo estacionariedad.

## ⚠ Caso no estacionario

- Si  $|\phi| \geq 1$ :
  - Varianza diverge:  $\text{Var}(X_t) \rightarrow \infty$
  - No se cumple estacionariedad.
  - OLS produce estimaciones **no confiables**.

### Ejemplos:

- $\phi = 1$ : Random Walk (camino aleatorio).
- $\phi = -1$ : Alternancia con acumulación de choques.

## Conclusiones

1. **Ruido blanco** → no hay dependencia temporal;  $ACF \approx 0$ .
2. **AR(1)** → dependencia que decae como  $r(h) = \phi^h$ .
3. Estimación OLS de  $\phi$  es **consistente** si  $|\phi| < 1$ .
4. Si  $|\phi| \geq 1$ , el proceso **no es estacionario** y la varianza se vuelve infinita.

## Referencias

- Box, G.E.P., Jenkins, G.M., Reinsel, G.C. (2008). *Time Series Analysis: Forecasting and Control*. Wiley.
- Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
- Chatfield, C. (2003). *The Analysis of Time Series: An Introduction*. Chapman & Hall/CRC.



🏁 Fin de la presentación

Gracias por su atención.