



# Tarea 3 — Análisis de Series de Tiempo

Curso: Análisis de Datos

Autor: Carlos Solares

Fecha: 31/10/2025

## Objetivo general

Analizar el comportamiento de dos procesos estocásticos fundamentales:

1. **Ruido blanco** — proceso sin dependencia temporal.
2. **Proceso autoregresivo AR(1)** — proceso con dependencia del pasado.

Se estudian sus propiedades de **estacionariedad, autocorrelación y estimación de parámetros**.

## Fundamentos teóricos

- Una **serie de tiempo** es una realización de un proceso aleatorio dependiente del tiempo.
- En un proceso estacionario:
  - (  $E[X_t] = \mu$  )
  - (  $\operatorname{Var}(X_t) = \sigma^2$  )
  - (  $\operatorname{Cov}(X_t, X_{t+h}) = \gamma(h)$  )
- La **función de autocorrelación (ACF)** mide:

$$r(h) = \frac{\operatorname{Cov}(X_t, X_{t-h})}{\operatorname{Var}(X_t)}$$

## Inciso 3 — Ruido Blanco

Proceso simulado

$$X_t \sim \mathcal{N}(0, 1)$$

- No presenta memoria ni correlación temporal.
- La ACF debe ser ( $\approx 0$ ) para todo ( $h \geq 1$ ).

## ⚙ Implementación

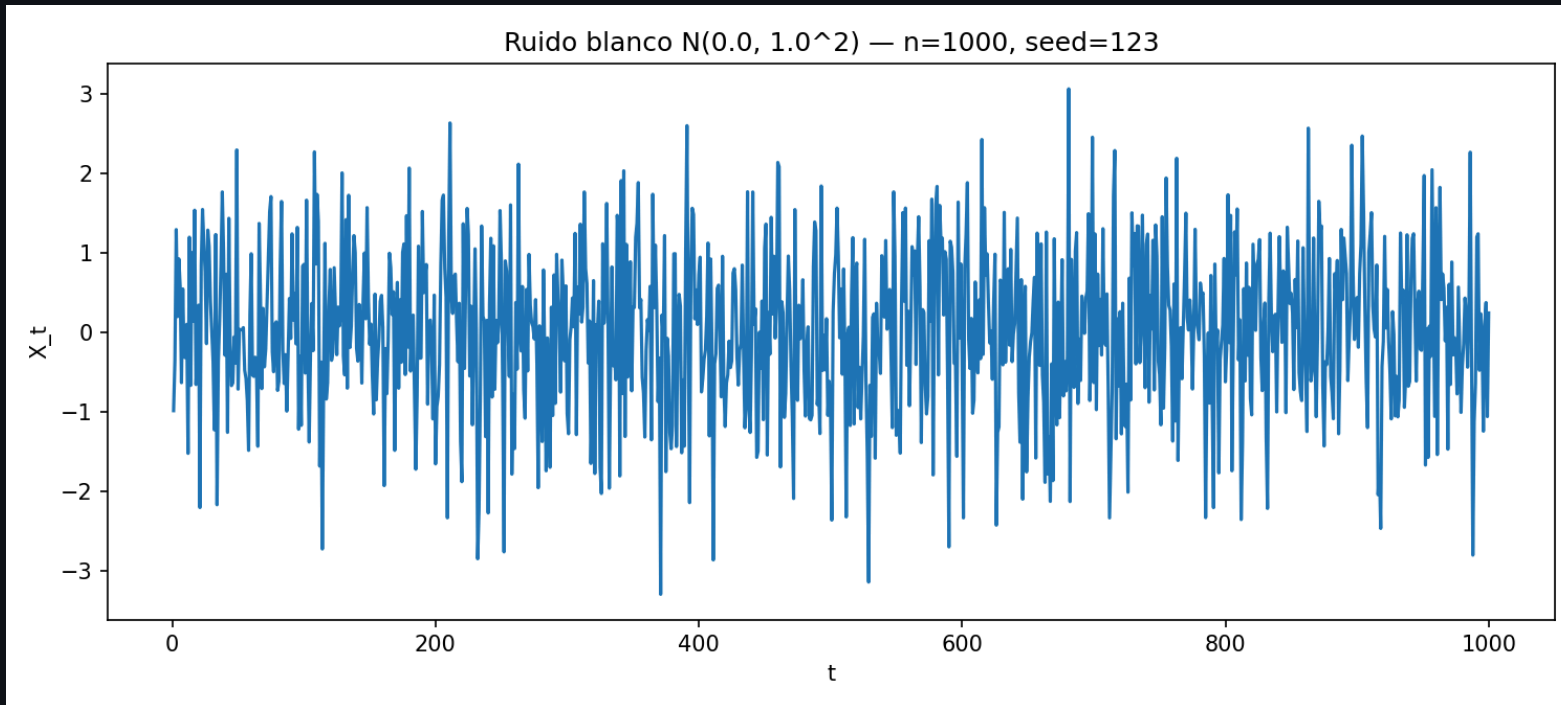
```
cd "Inciso 3"
python -m venv .venv
.venv\Scripts\Activate.ps1      # En Windows (PowerShell)
# source .venv/bin/activate     # En macOS/Linux
pip install numpy matplotlib

python simulate_white_noise_acf.py --n 1000 --lags 40
```

- Se generan 1000 observaciones.
- Se calcula la ACF muestral.
- Se grafican la serie y su ACF con bandas ( $\pm 1.96/\sqrt{T}$ ).




## Resultados — Serie simulada



- Distribución normal sin tendencia.
- Valores centrados en cero.



## Resultados — ACF del ruido blanco



- La ACF es ( $\approx 0$ ) para todos los lags (dentro de bandas).
- Confirma independencia temporal → **ruido blanco**.

## Inciso 6 — Proceso AR(1)

### Modelo

$$X_t = \phi X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2)$$

Parámetros:

$$\phi = 0.7, \quad \sigma = 1, \quad T = 200$$

- La ACF teórica es (  $r(h) = \phi^{|h|}$  ).
- Se espera un decrecimiento geométrico con  $(h)$ .



## Implementación

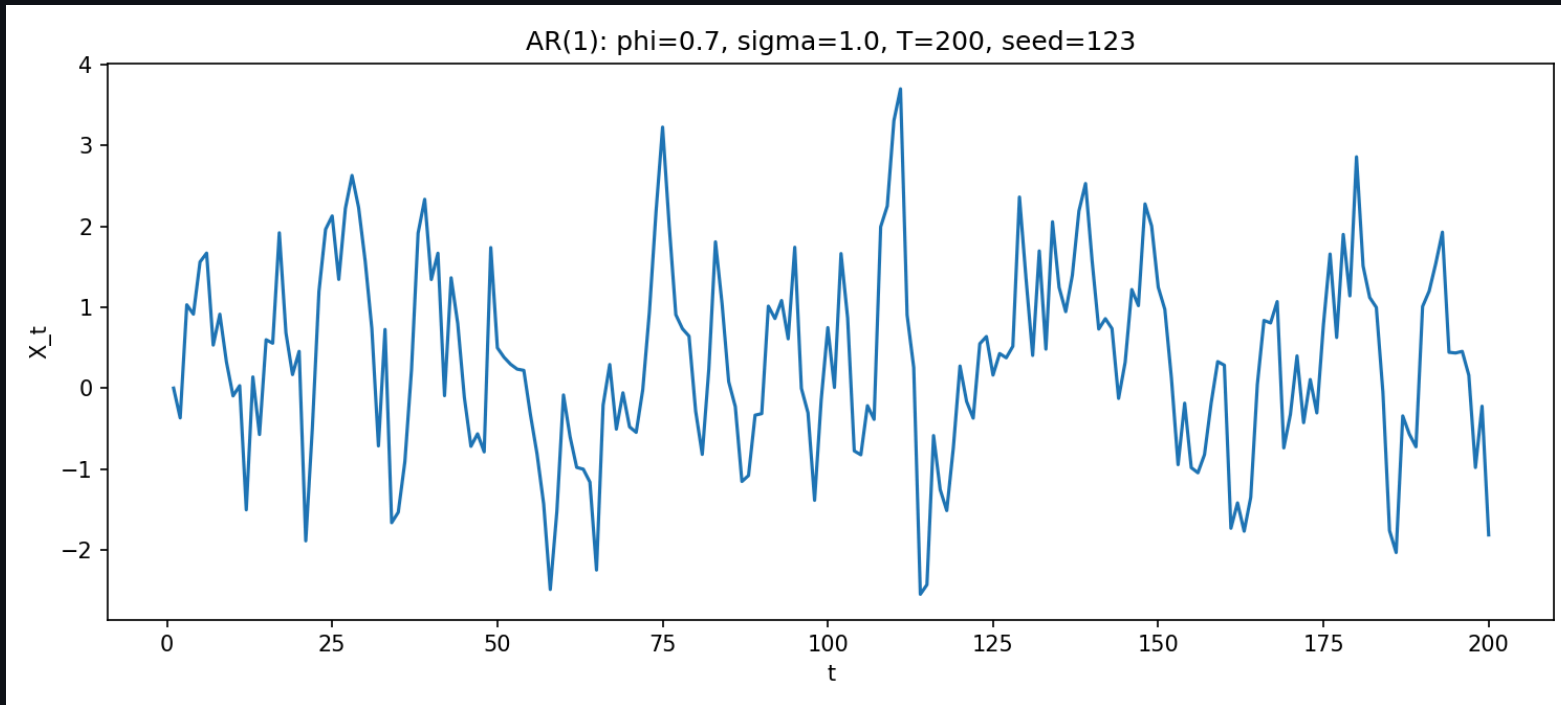
```
cd "Inciso 6"
python -m venv .venv
.venv\Scripts\Activate.ps1      # En Windows (PowerShell)
# source .venv/bin/activate     # En macOS/Linux
pip install numpy matplotlib

python simulate_ar1_acf.py --phi 0.7 --sigma 1 --T 200 --lags 40
```

- Simula AR(1) estacionario.
- Calcula la ACF muestral.
- Estima  $\hat{\phi}$  con OLS en  $X_t = \beta X_{t-1} + \varepsilon_t$ .




## Serie AR(1) simulada



- Presenta correlación positiva entre periodos consecutivos.
- Valores suavizados por el efecto de memoria.



## ACF del proceso AR(1)



- ACF decrece geométricamente con  $(h)$ .
- Forma típica de un **proceso autoregresivo**.
- Confirma dependencia temporal.

## Estimación de ( $\phi$ )

Regresión lineal:

$$X_t = \beta X_{t-1} + \varepsilon_t$$

Resultado:

$$\hat{\phi} \approx 0.7$$

➡ Estimación **muy cercana** al valor real → OLS válido bajo estacionariedad.

## ⚠ Caso no estacionario

- Si ( $|\phi| \geq 1$ ):
  - Varianza diverge: ( $\operatorname{Var}(X_t) \rightarrow \infty$ )
  - No se cumple estacionariedad.
  - OLS produce estimaciones **no confiables**.

### Ejemplos:


- ( $\phi=1$ ): Random Walk (camino aleatorio).
- ( $\phi=-1$ ): Alternancia con acumulación de choques.

## Conclusiones

1. **Ruido blanco** → no hay dependencia temporal; ACF ( $\approx 0$ ).
2. **AR(1)** → dependencia que decae como ( $r(h) = \phi^h$ ).
3. Estimación OLS de ( $\phi$ ) es **consistente** si ( $|\phi| < 1$ ).
4. Si ( $|\phi| \geq 1$ ), el proceso **no es estacionario** y la varianza se vuelve infinita.

## Referencias

- Box, G.E.P., Jenkins, G.M., Reinsel, G.C. (2008). *Time Series Analysis: Forecasting and Control*. Wiley.
- Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
- Chatfield, C. (2003). *The Analysis of Time Series: An Introduction*. Chapman & Hall/CRC.

 Fin de la presentación

Gracias por su atención.